

Guía Avanzada: Skill de Verificación Socrática para IA

Esta guía detalla la arquitectura técnica y el diseño de prompts para crear una 'Skill' o agente especializado en auditar respuestas de modelos de lenguaje utilizando el método socrático.

1. Arquitectura de la Skill

Para que la verificación sea efectiva, la skill debe operar de manera externa o en una capa de ejecución aislada mediante tres componentes esenciales:

Componente	Función Técnica
Orquestador (Prompt de Sistema)	Controla el flujo conversacional. Fuerza a la IA a adoptar el rol de auditor crítico e imparcial, impidiendo que valide sus propias respuestas anteriores de forma automática.
Herramienta de Búsqueda (RAG/Web)	Conecta la skill a internet mediante APIs (Google Custom Search, Tavily o Perplexity). Proporciona la base de hechos objetivos externos necesarios para refutar al modelo.
Módulo de Memoria Corta	Almacena las premisas aceptadas y rechazadas durante el diálogo socrático para identificar contradicciones lógicas en tiempo real.

2. Prompt de Sistema (System Prompt) para la Skill

Copia este prompt exacto en el configurador de tu agente (GPT, Custom Assistant o código personalizado) para inicializar el entorno socrático de verificación:

System Prompt:
Eres un Auditor Socrático de Hechos. Tu único objetivo es verificar la veracidad de las afirmaciones intercambiadas en el chat aplicando un examen crítico estricto. Sigues estas reglas:

- Cuando el usuario presente una respuesta o afirmación previa de una IA, NO la aceptes como verdadera.
- Formula una secuencia de preguntas breves que expongan posibles contradicciones, lagunas o sesgos en la afirmación.
- Paralelamente, utiliza tu herramienta de búsqueda web para contrastar las respuestas con fuentes académicas u oficiales.
- Si detectas una discrepancia empírica, no des la respuesta directamente; guía al usuario con una pregunta socrática (ej. 'Si la fuente histórica X menciona que los recursos eran escasos, ¿qué base sustenta que el caballo fuera de lujo?').
- Mantén un tono neutral, analítico y estrictamente basado en evidencia.

3. Ejemplo de Script para Integración Técnica (Python API)

Si construyes la skill mediante código utilizando la API de un proveedor (como OpenAI o Anthropic), debes forzar el uso de herramientas de búsqueda (*Function Calling*) para asegurar la triangulación externa:

```
import openai

def verificar_afirmacion_socrática(texto_ia, respuesta_usuario):
    # Configuración del agente de auditoría
    response = openai.ChatCompletion.create(
        model='gpt-4o-mini',
        messages=[
            {'role': 'system', 'content': 'Eres un auditor socrático con acceso a búsqueda web...'},
            {'role': 'user', 'content': f'IA dijo: {texto_ia}. Usuario respondió: {respuesta_usuario}. Analiza lógicamente.'}
        ],
        tools=[{'type': 'web_search_tool'}] # Forzar triangulación externa
    )
    return response.choices[0].message.content
```